Detecção de fraude em cartão de crédito

Contexto

É importante que as empresas de cartão de crédito sejam capazes de reconhecer transações fraudulentas com cartão de crédito para que os clientes não sejam cobrados por itens que não compraram.

Conteúdo

O conjunto de dados contém transações feitas por cartões de crédito em setembro de 2013 por titulares de cartões europeus.

Este conjunto de dados apresenta transações ocorridas em dois dias, onde temos 492 fraudes em 284.807 transações. O conjunto de dados é altamente desbalanceado, a classe positiva (fraudes) responde por 0,172% de todas as transações.

Ele contém apenas variáveis de entrada numéricas que são o resultado de uma transformação PCA. Infelizmente, devido a questões de confidencialidade, não podemos fornecer os recursos originais e mais informações básicas sobre os dados. As características V1, V2, ... V28 são os principais componentes obtidos com PCA, as únicas características que não foram transformadas com PCA são 'Time' e 'Amount'. O recurso 'Tempo' contém os segundos decorridos entre cada transação e a primeira transação no conjunto de dados. O recurso 'Valor' é o valor da transação, esse recurso pode ser usado para aprendizado sensível ao custo dependente de exemplo. A característica 'Classe' é a variável de resposta e assume valor 1 em caso de fraude e 0 caso contrário.

Dada a taxa de desequilíbrio de classe, recomendamos medir a precisão usando a Área sob a Curva de Rechamada de Precisão (AUPRC). A precisão da matriz de confusão não é significativa para a classificação desbalanceada.

```
import math
import pandas as pd
import graphviz
import pydot
import chart_studio.plotly as py
import plotly.figure_factory as ff
import seaborn as sea
import matplotlib.pyplot as plt
from wand.image import Image as WImage
```

```
data = pd.read csv(r'dados/creditcard.csv',sep=',')
        data.head(4)
Out[]:
                                V2
                                                                                                 V9 ...
                                                                                                             V21
                                                                                                                       V22
           Time
                      V1
                                         V3
                                                  V4
                                                            V5
                                                                      V6
                                                                               V7
                                                                                        V8
                                                                                                                                V23
                                                                                                                                          V24
                                             1.378155 -0.338321
                                                                0.462388
                                                                          0.239599 0.098698
                                                                                            0.363787 ... -0.018307
             0.0 -1.359807 -0.072781 2.536347
                                                                                                                  0.277838
                                                                                                                           -0.110474
                 1.191857
                           0.266151 0.166480
                                             0.448154
                                                       0.060018
                                                                -0.082361 -0.078803 0.085102 -0.255425 ... -0.225775
                                                                                                                 -0.638672
                                                                                                                            0.101288 -0.339846
        1
             1.0 -1.358354 -1.340163 1.773209
                                             0.379780
                                                      -0.503198
                                                                1.800499
                                                                          0.791461  0.247676  -1.514654  ...  0.247998
                                                                                                                  0.771679
                                                                                                                            0.909412 -0.689281
            1.0 -0.966272 -0.185226 1.792993 -0.863291 -0.010309
                                                                          3
                                                                1.247203
                                                                                                                  0.005274 -0.190321 -1.175575
       4 rows × 31 columns
```

```
In [ ]: data.shape
Out[ ]: (284807, 31)
```

Analise Exploratoria de dados

- 1. Usei data.info() para me informa se no dataframe possui valores nulo eo tipo do atributo
- 2. Usei o .describe() no qual ele me statísticas descritiva cada atributo. Seaborn para plotar
- 3. Correlação de dados os que me deram maior correlacao foi positiva V7,V8 em relacao ao Amount
- 4. Devido possui muitos dados o pairplot demorava muito para renderizar, então peguei os atributos de maior correlacao.
- 5. Fiz a media dos atributos em relação Class
- 6. statísticas descritiva em relação ao atributoo Class usando plotly

```
In [ ]: data.info()
```

```
Column Non-Null Count
                                    Dtype
            _ _ _ _ _ _
                    -----
       0
            Time
                    284807 non-null float64
       1
            ٧1
                   284807 non-null float64
       2
            ٧2
                   284807 non-null float64
            ٧3
                    284807 non-null float64
            ٧4
                    284807 non-null float64
       4
       5
            ۷5
                   284807 non-null float64
       6
            ۷6
                   284807 non-null float64
       7
            ٧7
                    284807 non-null float64
       8
            V8
                    284807 non-null float64
            ۷9
       9
                    284807 non-null float64
           V10
                   284807 non-null float64
       10
           V11
       11
                   284807 non-null float64
       12
           V12
                   284807 non-null float64
       13
           V13
                   284807 non-null float64
           V14
                    284807 non-null float64
       14
       15
           V15
                   284807 non-null float64
       16
           V16
                    284807 non-null float64
           V17
       17
                   284807 non-null float64
           V18
                   284807 non-null float64
       18
           V19
       19
                   284807 non-null float64
           V20
        20
                   284807 non-null float64
       21
           V21
                    284807 non-null float64
           V22
       22
                   284807 non-null float64
           V23
       23
                   284807 non-null float64
           V24
                   284807 non-null float64
       24
           V25
                   284807 non-null float64
        26
           V26
                   284807 non-null float64
           V27
       27
                   284807 non-null float64
           V28
                   284807 non-null float64
           Amount
                   284807 non-null float64
        30
          Class
                   284807 non-null int64
      dtypes: float64(30), int64(1)
      memory usage: 67.4 MB
In [ ]: plt.figure(figsize=(10,8))
        sea.set theme(style="whitegrid")
        sea.heatmap(data.describe().T,annot=True,robust=True)
Out[]: <Axes: >
```


<class 'pandas.core.frame.DataFrame'>
RangeIndex: 284807 entries, 0 to 284806

Data columns (total 31 columns):

Time	2.8e+05	9.5e+04	4.7e+04	0	5.4e+04	8.5e+04	1.4e+05	1.7e+05	
V1	2.8e+05	1.2e-15	2	-56	-0.92	0.018	1.3	2.5	
V2	2.8e+05	3.4e-16	1.7	-73	-0.6	0.065	0.8	22	
V3	2.8e+05	-1.4e-15	1.5	-48	-0.89	0.18	1	9.4	- 250000
V4	2.8e + 05	2.1e-15	1.4	-5.7	-0.85	-0.02	0.74	17	250000
V5	2.8e+05	9.6e-16	1.4	-1.1e+02	-0.69	-0.054	0.61	35	
V6	2.8e+05	1.5e-15	1.3	-26	-0.77	-0.27	0.4	73	
V7	2.8e+05	-5.6e-16	1.2	-44	-0.55	0.04	0.57	1.2e+02	
V8	2.8e+05	1.2e-16	1.2	-73	-0.21	0.022	0.33	20	
V9	2.8e+05	-2.4e-15	1.1	-13	-0.64	-0.051	0.6	16	- 200000
V10	2.8e+05	2.2e-15	1.1	-25	-0.54	-0.093	0.45	24	
V11	2.8e+05	1.7e-15	1	-4.8	-0.76	-0.033	0.74	12	
V12	2.8e + 05	-1.2e-15	1	-19	-0.41	0.14	0.62	7.8	
V13	2.8e + 05	8.2e-16	1	-5.8	-0.65	-0.014	0.66	7.1	
V14	2.8e + 05	1.2e-15	0.96	-19	-0.43	0.051	0.49	11	- 150000
V15	2.8e + 05	4.9e-15	0.92	-4.5	-0.58	0.048	0.65	8.9	
V16	2.8e + 05	1.4e-15	0.88	-14	-0.47	0.066	0.52	17	
V17	2.8e + 05	-3.8e-16	0.85	-25	-0.48	-0.066	0.4	9.3	
V18	2.8e + 05	9.6e-16	0.84	-9.5	-0.5	-0.0036	0.5	5	
V19	2.8e + 05	1e-15	0.81	-7.2	-0.46	0.0037	0.46	5.6	100000
V20	2.8e + 05	6.4e-16	0.77	-54	-0.21	-0.062	0.13	39	- 100000
V21	2.8e + 05		0.73	-35	-0.23	-0.029	0.19	27	
V22	2.8e + 05		0.73	-11	-0.54	0.0068	0.53	11	
V23	2.8e + 05	2.6e-16	0.62	-45	-0.16	-0.011	0.15	23	
V24	2.8e + 05	4.5e-15	0.61	-2.8	-0.35	0.041	0.44	4.6	
V25	2.8e+05	5.3e-16	0.52	-10	-0.32	0.017	0.35	7.5	- 50000
V26	2.8e+05		0.48	-2.6	-0.33	-0.052	0.24	3.5	
V27	2.8e+05	-3.7e-16	0.4	-23	-0.071	0.0013	0.091	32	
V28	2.8e+05	-1.2e-16	0.33	-15	-0.053	0.011	0.078	34	
Amount	2.8e+05	88	2.5e+02		5.6	22	77	2.6e+04	
Class	2.8e+05	0.0017	0.042	0	0	0	0	1	- 0
	count	mean	std	min	25%	50%	75%	max	_

In []: plt.figure(figsize=(14,10))
 sea.heatmap(data.corr())

Out[]: <Axes: >





```
In []: df1 = (data[['Amount', 'Time', 'Class', 'V7', 'V20']]).loc[data['Class']==0]
    df2 = (data[['Amount', 'Time', 'Class', 'V7', 'V20']]).loc[data['Class']==1]

    df1 = df1.sample(480, random_state=50)
    df2 = df2.sample(480)
    data_2 = pd.concat([df1,df2],axis=0)

    plt.figure(figsize=(12,8))
    sea.set_theme(style="whitegrid")
    sea.pairplot(data_2,hue='Class')
```

Ë






Usei a regressao logistica , Naive bayes

```
In [ ]: X = data.drop(columns='Class').values
Y = data['Class'].values
```

Regressão Logistica

```
In [ ]: x train , x test , y train , y test = train test split(X,Y,test size=0.30)
        logistic = LogisticRegression()
In [ ]: y pred = logistic.fit(x train,y train).predict(x test)
      /home/mateus/MEGA/Matérias UFC CD/Introdução a Mineração de Dados/venv/lib/python3.11/site-packages/sklearn/linear model/ logist
      ic.py:458: ConvergenceWarning:
      lbfgs failed to converge (status=1):
      STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
      Increase the number of iterations (max iter) or scale the data as shown in:
          https://scikit-learn.org/stable/modules/preprocessing.html
      Please also refer to the documentation for alternative solver options:
           https://scikit-learn.org/stable/modules/linear model.html#logistic-regression
In [ ]: print(classification report(y test,y pred))
                     precision
                                  recall f1-score
                                                     support
                                    1.00
                                                       85281
                  0
                          1.00
                                              1.00
                                    0.72
                                              0.73
                          0.75
                                                         162
                                                       85443
                                              1.00
           accuracy
          macro avq
                         0.88
                                    0.86
                                              0.87
                                                       85443
      weighted avg
                         1.00
                                    1.00
                                              1.00
                                                       85443
In [ ]: cm = confusion matrix(y test,y pred)
        ConfusionMatrixDisplay(cm).plot()
        plt.title(f'acuracia = {accuracy score(y test,y pred)}')
Out[]: Text(0.5, 1.0, 'acuracia = 0.9990168884519505')
```




desempenho do modelos de classificação


resultado bom cima de 80%

```
In []: plt.figure(figsize=(4,3))
    y_pred_prob = logistic.predict_proba(x_test)[::,1]
    fpr, tpr, null = roc_curve(y_test, y_pred_prob)
    auc = roc_auc_score(y_test,y_pred_prob)
    plt.plot(fpr,tpr,label="data 1, auc="+str(auc))
    plt.legend(loc=4)
```

Out[]: <matplotlib.legend.Legend at 0x7f4b8f60d250>




Naive Bayes



```
In []: plt.figure(figsize=(4,3))
    y_pred_prob = logistic.predict_proba(x_test)[::,1]
    fpr, tpr, null = roc_curve(y_test, y_pred_prob)
    auc = roc_auc_score(y_test,y_pred_prob)
    plt.plot(fpr,tpr,label="data 1, auc="+str(auc))
    plt.legend(loc=4)
```

Out[]: <matplotlib.legend.Legend at 0x7f4b8f60f9d0>



Rede neural

```
In []: import tensorflow as ts

2023-07-04 20:51:03.514741: I tensorflow/tsl/cuda/cudart_stub.cc:28] Could not find cuda drivers on your machine, GPU will not be used.
2023-07-04 20:51:03.598382: I tensorflow/tsl/cuda/cudart_stub.cc:28] Could not find cuda drivers on your machine, GPU will not be used.
2023-07-04 20:51:03.600282: I tensorflow/core/platform/cpu_feature_guard.cc:182] This TensorFlow binary is optimized to use available CPU instructions in performance-critical operations.
To enable the following instructions: AVX2 FMA, in other operations, rebuild TensorFlow with the appropriate compiler flags.
2023-07-04 20:51:05.181352: W tensorflow/compiler/tf2tensorrt/utils/py_utils.cc:38] TF-TRT Warning: Could not find TensorRT

In []: ann = ts.keras.models.Sequential()

In []: ann.add(ts.keras.layers.Flatten())
ann.add(ts.keras.layers.Dense(units= 32,activation='relu'))
ann.add(ts.keras.layers.Dense(units= 32,activation='relu'))
ann.add(ts.keras.layers.Dense(units= 1,activation='sigmoid'))
```

Imagens do modelo estão ./plots/


• plotar a representação grafica da rede ela estão na pasta plot no arquivo .pdf

```
In [ ]: try:
     dot model = ts.keras.utils.model to dot(ann, show shapes=True, show layer names=True, dpi=96)
     graph = graphviz.Source(dot model.to string())
     graph.render('./"Plot da rede neural"/guestao 1 plot modeloTENSOR', format='png', cleanup=True)
     graph.view('./plots/questao 1 plot modeloTENSOR.png')
   except Exception:
     print('ERROR')
In []: ann.compile(optimizer = 'adam', loss = 'binary crossentropy', metrics = ['accuracy'])
In [ ]: treino = ann.fit(x train, y train, batch size = 200 ,epochs = 10)
   Epoch 1/10
   2023-07-04 20:51:06.835647: W tensorflow/tsl/framework/cpu allocator impl.cc:83] Allocation of 23923680 exceeds 10% of free syst
   em memory.
   Epoch 2/10
   Epoch 3/10
   Epoch 4/10
   Epoch 5/10
   Epoch 6/10
   Epoch 7/10
   Epoch 8/10
   Epoch 9/10
   Epoch 10/10
   In []: y pred ANN = ((ann.predict(x test)>0.5)*1).T[0]
```

```
In [ ]: cm = confusion_matrix(y_test,y_pred_ANN)

ConfusionMatrixDisplay(cm).plot()
plt.title(f"Acuracia = {accuracy_score(y_test,y_pred_ANN)}")
```

Out[]: Text(0.5, 1.0, 'Acuracia = 0.9981157028662383')



Teste | Ideia

- equalizando
 - possuem mais dados de não fraude. A ideia é pegar a mesma quantidade valores de fraude aleatoriamente

Ocorre diminuição quantidade de dados

```
data['Class'].value counts()
Out[]: Class
        0
              284315
        1
                 492
        Name: count, dtype: int64
        Pegar mesma quantidade de valores da Class == 1 mas pegando aleatoriamente 492 valores de 284215 por meio da função sample do python

    com o radom state 42

              dependendo do valores de random state isso ira me da uma acuracia muito alta ou não
        data nao fraude = data.loc[data['Class']==0]
        data nao fraude = data nao fraude.sample(492,random state=42)
        data nao fraude.shape
Out[]: (492, 31)
In [ ]: data fraude = data.loc[data['Class']==1]
        data fraude.shape
Out[]: (492, 31)
In [ ]: new data = pd.concat([data fraude,data nao fraude],axis=0)
        new data.shape
Out[]: (984, 31)
In [ ]: X = (new data.drop(columns='Class')).values
        Y = new data['Class'].values
In [ ]: x_train , x_test , y_train , y_test = train_test_split(X,Y,test_size=0.30)
        logistic = LogisticRegression()
In [ ]: y pred = logistic.fit(x train,y train).predict(x test)
```

```
/home/mateus/MEGA/Matérias UFC CD/Introdução a Mineração de Dados/venv/lib/python3.11/site-packages/sklearn/linear_model/_logist
ic.py:458: ConvergenceWarning:

lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

In []: cm = confusion_matrix(y_test,y_pred)
ConfusionMatrixDisplay(cm).plot()
    plt.title(f'acuracia = {accuracy score(y test,y pred)}')
```

Out[]: Text(0.5, 1.0, 'acuracia = 0.9155405405405406')

